

**АЛЬФА
БУДУЩЕЕ**

Альфа Банк

Магистратура Альфа-Банка и МФТИ

КРЕДИТНЫЙ СКОРИНГ

Аннотация



Научитесь предсказывать вероятность выхода клиента в дефолт по кредиту. Вам необходимо, опираясь на данные карточных транзакций пользователей разработать алгоритм, который с высокой степенью точности сможет определить вероятность неплатежа клиента по займам в течение более чем 3 месяцев в рамках года.



Постановка задачи



Разработайте модель прогнозирования выхода клиента в дефолт, на основании истории карточных транзакций. Модель должна качественно отделять потенциальных клиентов-неплательщиков от тех, кто способен выплачивать полученный займ. Для успешного достижения поставленной цели:

01

Изучите предоставленные данные о клиентах, а также истории их транзакций за предоставленный период.

02

Проанализируйте взаимосвязи между признаками и выходом клиента в дефолт.

03

Постройте модель на тренировочных данных и оцените ее качество.

04

Сделайте предсказание вероятности выхода в дефолт для тестовой выборки

05


Сохраните результат в формате CSV и отправьте решение на платформу.

06

Доработайте модель, чтобы повысить значение метрики ROC-AUC.

ВАЖНО!

Вы имеете право загружать ваше предсказание на платформу в формате CSV не более 3 раз в течение одного дня (в промежутке между 00:00 и 23:59 по МСК).



Бизнес-контекст




Кредитный скоринг представляет собой одну из наиболее классических банковских задач. Перед выдачей клиенту кредита, банк обязан оценить вероятность того, что выданные деньги не будут возвращены. Для того, чтобы качественно оценить вероятность на каждом клиенте банк использует собранные исторические данные карточных транзакций, после чего проводит оценку клиента.

Каждый пользователь в представленных данных имеет различный как по своему содержанию, так и по своей длительности набор карточных транзакций. Задачу кредитного скоринга можно решать с помощью классических моделей, таких как логистическая

регрессия и градиентный бустинг. Однако подобные подходы основаны на формировании агрегатов, таких как среднее, минимум, максимум, медиана и дисперсия на фиксированных временных отрезках.

В то же время классические подходы не всегда учитывают все связи между транзакциями, а также требуют слишком специализированной подготовки данных, чтобы избежать потери данных при агрегировании.

В представленных данных тренировочная выборка представляет собой транзакции на N месяцев, а тестовая выборка - последующие K месяцев.



Бизнес-контекст



КРИТЕРИИ УСПЕХА

Основным критерием успешной модели считается способность качественно определять вероятность выхода клиента в дефолт.

Для оценки качества модели применяется метрика ROC-AUC. Она позволяет понять, насколько хорошо модель отделяет клиентов, которые смогли вернуть заемные средства, от тех, кому этого не удалось.

Чем выше значение ROC-AUC, тем лучше модель помогает банку выбирать наиболее перспективных клиентов для выдачи кредитов.

ОГРАНИЧЕНИЯ

Для создания и настройки модели вы можете использовать язык Python версии 3.10 и выше. Также вы можете использовать любую библиотеку для машинного обучения и предобработки данных, являющуюся Open Source-ресурсом. Использование закрытых библиотек, частных API и чужого кода, не подпадающего под разрешение о свободном распространении и использовании, запрещено.



Бизнес-контекст



ИСТОЧНИКИ ИНФОРМАЦИИ

(Ссылка на данные)

Полный датасет был разделен несколько датасетов одинаковой структуры и содержания:

- Тренировочный датасет с данными **train_data.parquet**
- Тестовый датасет с данными **test_data.parquet**

Каждый из датасетов содержит следующие признаки:

- **id** – идентификатор заявки. Заявки пронумерованы так, что большему номеру соответствует более поздняя дата заявки
- **rn** – порядковый номер кредитного продукта в кредитной истории. Большему номеру соответствует продукт с более поздней датой открытия
- **pre_since_opened** – дней с даты открытия кредита до даты сбора данных (бинаризованный формат)
- **pre_since_confirmed** – дней с даты подтверждения информации по кредиту до даты сбора данных (бинаризованный формат)
- **pre_pterm** – плановое количество дней с даты открытия кредита до даты закрытия (бинаризованный формат)
- **pre_fterm** – фактическое количество дней с даты открытия кредита до даты закрытия (бинаризованный формат)
- **pre_till_pclose** – плановое количество дней с даты сбора данных до даты закрытия кредита (бинаризованный формат)
- **pre_till_fclose** – фактическое количество дней с даты сбора данных до даты закрытия кредита (бинаризованный формат)
- **pre_loans_credit_limit** – кредитный лимит (бинаризованный формат)
- **pre_loans_next_pay_summ** – сумма следующего платежа по кредиту (бинаризованный формат)
- **pre_loans_outstanding** – оставшаяся невыплаченная сумма кредита (бинаризованный формат)
- **pre_loans_total_overdue** – текущая просроченная задолженность (бинаризованный формат)
- **pre_loans_max_overdue_sum** – максимальная просроченная задолженность (бинаризованный формат)
- **pre_loans_credit_cost_rate** – полная стоимость кредита (бинаризованный формат)
- **pre_loans5** – число просрочек до 5 дней (бинаризованный формат)
- **pre_loans530** – число просрочек от 5 до 30 дней (бинаризованный формат)
- **pre_loans3060** – число просрочек от 30 до 60 дней (бинаризованный формат)
- **pre_loans6090** – число просрочек от 60 до 90 дней (бинаризованный формат)
- **pre_loans90** – число просрочек более, чем на 90 дней (бинаризованный формат)
- **is_zero_loans_5** – флаг: нет просрочек до 5 дней
- **is_zero_loans_530** – флаг: нет просрочек от 5 до 30 дней
- **is_zero_loans_3060** – флаг: нет просрочек от 30 до 60 дней

Бизнес-контекст



- **is_zero_loans_6090** – флаг: нет просрочек от 60 до 90 дней
- **is_zero_loans90** – флаг: нет просрочек более, чем на 90 дней
- **pre_util** – отношение оставшейся невыплаченной суммы кредита к кредитному лимиту (бинаризованный формат)
- **pre_over2limit** – отношение текущей просроченной задолженности к кредитному лимиту (бинаризованный формат)
- **pre_maxover2limit** – отношение максимальной просроченной задолженности к кредитному лимиту (бинаризованный формат)
- **is_zero_util** – флаг: отношение оставшейся невыплаченной суммы кредита к кредитному лимиту равняется 0
- **is_zero_over2limit** – флаг: отношение текущей просроченной задолженности к кредитному лимиту равняется 0
- **is_zero_maxover2limit** – флаг: отношение максимальной просроченной задолженности к кредитному лимиту равняется 0
- **enc_paym_{0..N}** – статусы ежемесячных платежей за последние N месяцев (закодировано)
- **enc_loans_account_holder_type** – тип отношения к кредиту (закодировано)
- **enc_loans_credit_status** – статус кредита (закодировано)
- **enc_loans_account_cur** – валюта кредита (закодировано)
- **enc_loans_credit_type** – тип кредита (закодировано)
- **pclose_flag** – флаг: плановое количество дней с даты открытия кредита до даты закрытия не определено
- **fclose_flag** – флаг: фактическое количество дней с даты открытия кредита до даты закрытия не определено
- Файл **train_target.csv** – файл с конечными классами клиентов, информация о которых описана в тренировочных данных. Содержит следующие признаки:
 - **id** – идентификатор заявки
 - **flag** – целевая переменная, 1 – факт ухода в дефолт. Доступна на обучающей выборке
- Файл **sample_submission.csv** – пример файла сабмита для отправки на платформу. Содержит следующие признаки:
 - **id** – идентификатор заявки
 - **flag** – предсказание, полученное моделью

Бизнес-контекст




ПРОСТРАНСТВО РЕШЕНИЙ

Для обучения модели вы можете использовать только данные, предоставленные в тренировочной и тестовой выборке.

В своем решении вы можете:

- обучить модель на части датасета;
- использовать только часть признаков;
- создавать новые признаки на основе имеющихся данных;
- анализировать данные и связи между ними
- строить признаки финансовой активности клиента за разные периоды;
- проводить селекцию и отбор признаков;
- использовать ансамбли моделей;
- подбирать гиперпараметры;
- сравнивать несколько подходов к моделированию.

Выбор модели не ограничен организаторами. Можно использовать любую модель из Open Source: логистическую регрессию, деревья решений, случайный лес, градиентный бустинг, нейронные сети, рекуррентные нейронные сети, трансформеры и другие подходы



О компании



Альфа-Банк — крупнейший универсальный частный банк в России. На протяжении 30 лет занимает ведущие позиции во всех сегментах банковского бизнеса.

О БАНКЕ В ЦИФРАХ

210 млрд рублей
чистая прибыль¹

40 млн
клиентская база
физических лиц

2 млн
корпоративных клиентов
(компаний малого и среднего
бизнеса)

800+
офисов в 28 регионах
присутствия

400+
продуктовых команд

800+
проектов в год

3-е место
в рейтинге российских банков
по объемам кредитования
физических лиц



АЛЬФА-БАНК — ПОБЕДИТЕЛЬ СЛЕДУЮЩИХ ПРЕМИЙ:

- Топ-1 работодатель по версии [HeadHunter](#), [Changellenge >>](#), [FutureToday](#)
- [Лучший мобильный банк](#) в браузере смартфона по версии Markswebb
- [Лучший сервис](#) для премиальных клиентов по версии Frank RG
- Alfa Digital — [лучший IT-бренд](#) работодателя в бигтехе в 2025 году по рейтингу IT-брендов работодателей от консалтинговой компании «ЭКОПСИ» и платформы «Хабр»
- Первым в стране получил статус [«Работодатель нового поколения»](#) как самый технологичный банк по результатам исследования Changellenge >> Best Company Award в 2025 и 2026

¹ Чистая прибыль банка по итогам 2024 года на основе международных стандартов финансовой отчетности (МСФО).

Приложение

МЕТРИКА ROC-AUC

Результат метрики ROC-AUC

Метрика ROC-AUC отражает качество модели бинарной классификации. Кривая ROC иллюстрирует производительность классификационной модели при всех порогах классификации. Для построения кривой ROC в качестве оси X берутся значения ложноположительной частоты FPR, которые рассчитываются по формуле:

$$FPR = \frac{FP}{TN+FP},$$

где FP — ложноположительные результаты, а TN — истинно отрицательные. Значение по оси Y рассчитывается как истинно положительная частота — TRP, или recall, которая рассчитывается по формуле:

$$TPR = \frac{TP}{TP + FN},$$

где TP — истинно положительные результаты, а FN — ложно отрицательные.

Показатель AUC — это сумма производительности модели, представленная в виде одного числа, т. е. измеренная площадь под кривой ROC, которая колеблется в диапазоне от 0 до 1, где с увеличением значения увеличивается и производительность модели.



CHANGELLENGE >>

Кейс написан и опубликован
Changellenge >> —
ведущей организацией
по кейсам в России.

www.changellenge.com

Альфа Банк

Кейс создан совместно
с АО «Альфа-Банк»

www.alfabank.ru

